Ingestão e Análise de Dados com Azure Databricks

Sumário

1	٧	Versão			
2	Introdução				
3	li	6			
	3.1	l Introdução	6		
	3.2	2 Armazenamento Inicial no Amazon S3	6		
4		Camadas de Provisionamento e Configuração de Serviços no Azure			
	4.1	l Resource Group	7		
	4.2	2 Storage Account	8		
	4.3	3 Container	9		
	4.4	4 Key Vault	10		
5	T	Transferência de Dados para o Azure Data Lake Storage (ADLS)	13		
6	6 Execução do Pipeline de Dados18				
7	7 Criação do Azure Databricks Workspace e Cluster				
8	8 Camada de Extração de Dados22				
9	9 Camada de Transformação e Análise de Dados2				
10)	Camada de Armazenamento de Dados	32		
1:	L	Camada de Consulta de Dados	38		
12	2 Conclusão				
13	3	Referência	41		

1 Versão

Este documento foi criado por Cleber Zumba de Souza e pode ser distribuído livremente, desde que a fonte seja mencionada.

Versão	Ação	Data
1.0	Criação do documento	26/07/2024

2 Introdução

Neste projeto, desenvolvi uma solução de engenharia de dados integrando as tecnologias da AWS, Azure e Databricks. O objetivo principal foi criar um pipeline de dados eficiente e escalável que abrange desde a ingestão de dados até a transformação e análise, garantindo armazenamento seguro e processamento robusto. Os dados tratados neste pipeline são relativos às chamadas de emergência do Corpo de Bombeiros de São Francisco.

Contexto e Objetivos

Em ambientes modernos de dados, é essencial integrar diferentes plataformas de nuvem e ferramentas para otimizar o fluxo de trabalho de dados. Este projeto foi projetado para:

- Ingestão de Dados: Ler dados de um bucket S3 na AWS.
- **Armazenamento Centralizado**: Armazenar os dados em um Data Lake no Azure Data Lake Storage (ADLS).
- Processamento e Análise: Utilizar o Databricks para transformar, analisar e armazenar os dados transformados.

Visão Geral dos Dados

Os dados utilizados neste pipeline são registros das chamadas de emergência atendidas pelo Corpo de Bombeiros de São Francisco. Esses dados contêm informações críticas, como a natureza da chamada, o bairro onde ocorreu, e os tempos de resposta. Analisar esses dados é vital para melhorar os serviços de emergência e a segurança pública.

Visão Geral das Tecnologias Utilizadas

- 1. **AWS S3**: Serviço de armazenamento na nuvem da Amazon onde os dados brutos são inicialmente armazenados.
- 2. **Azure Resource Group**: Agrupa e gerencia todos os recursos relacionados ao projeto na Azure.
- 3. **Azure Storage Account**: Fornece armazenamento seguro e escalável para dados no Azure.
- 4. **Azure Data Factory**: Serviço de integração de dados utilizado para orquestrar e automatizar o movimento de dados entre os serviços AWS S3 e ADLS.
- 5. **Azure Data Lake Storage (ADLS)**: Solução de armazenamento centralizada no Azure, que permite armazenamento eficiente e seguro dos dados.
- 6. **Databricks**: Plataforma de análise e processamento de dados baseada em Apache Spark, usada para transformar, analisar e armazenar dados.

Fluxo de Trabalho do Projeto

1. Ingestão de Dados com Azure Data Factory:

- Um pipeline de dados no Azure Data Factory lê o arquivo de dados armazenado no bucket S3 da AWS.
- Os dados são então transferidos e armazenados no Data Lake no Azure Data Lake Storage (ADLS).

2. Processamento e Análise com Databricks:

- o O Databricks integra-se ao ADLS para acessar os dados armazenados.
- Utilizando o poder de processamento do Apache Spark, os dados são transformados e analisados conforme as necessidades do projeto.
- Os dados transformados são então armazenados de volta no ADLS ou em outros destinos conforme necessário.

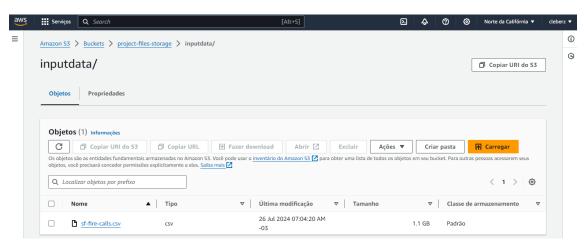
3 Ingestão de Dados

3.1 Introdução

Neste capítulo, detalhei o processo de ingestão de dados, desde a leitura do arquivo armazenado no bucket Amazon S3 até a transferência dos dados para o Azure Data Lake Storage (ADLS). Este é o primeiro passo no pipeline de dados e é crucial para garantir que os dados brutos estejam disponíveis para processamento e análise subsequentes.

3.2 Armazenamento Inicial no Amazon S3

Os dados de chamadas do Corpo de Bombeiros de São Francisco são inicialmente armazenados em um bucket Amazon S3. A imagem abaixo mostra a estrutura de armazenamento do arquivo sf-fire-calls.csv no bucket S3:



Bucket: project-files-storage

Diretório: inputdata
Arquivo: sf-fire-calls.csv

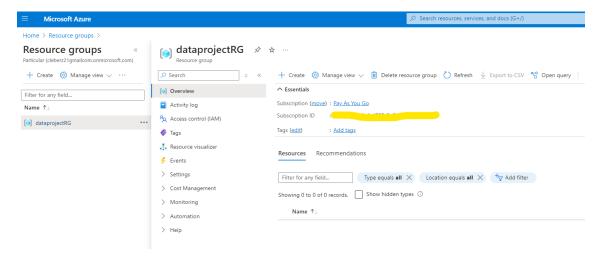
Tamanho: 1.1 GB

Última Modificação: 26 de Julho de 2024, 07:04 AM

4 Camadas de Provisionamento e Configuração de Serviços no Azure

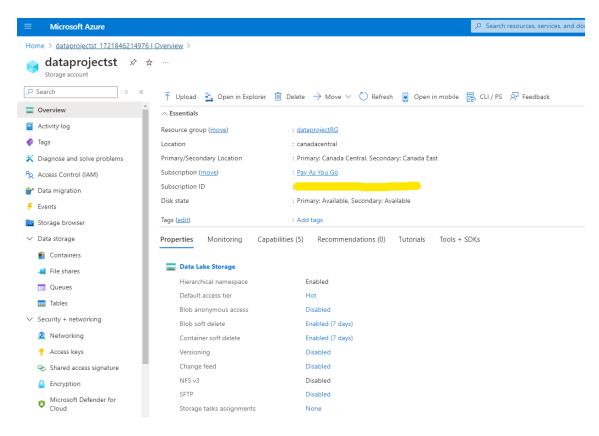
Antes de realizar a transferência de dados, foi necessário provisionar e configurar os serviços no Azure. As etapas incluem a criação de um Resource Group, uma Storage Account, um Container e um Key Vault

4.1 Resource Group



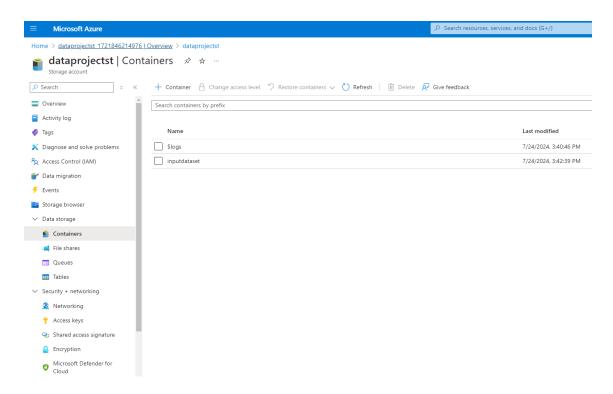
Um Resource Group foi criado para agrupar e gerenciar todos os recursos relacionados ao projeto na Azure. Isso facilita a organização e a administração dos recursos.

4.2 Storage Account



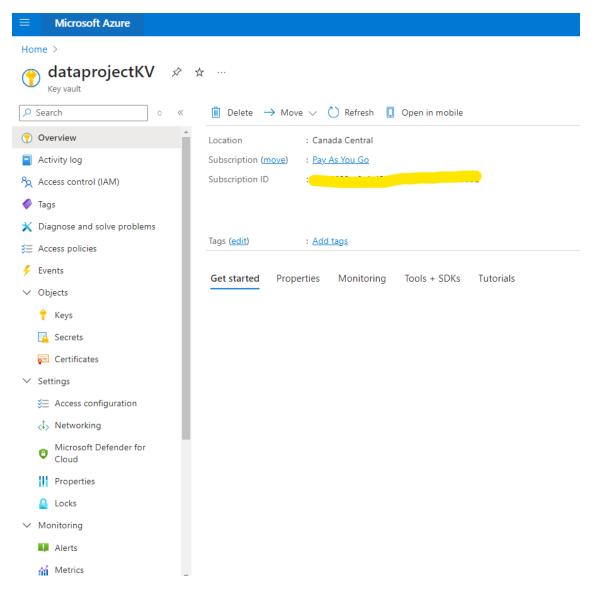
Uma Storage Account foi criada para fornecer armazenamento seguro e escalável para os dados. Esta conta de armazenamento é essencial para armazenar os dados transferidos do S3.

4.3 Container

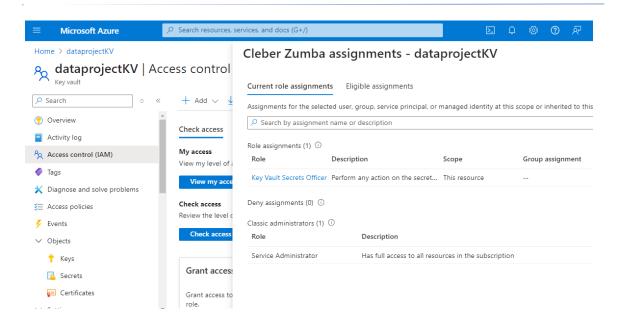


Dentro da Storage Account, um container foi criado para armazenar os dados no formato desejado.

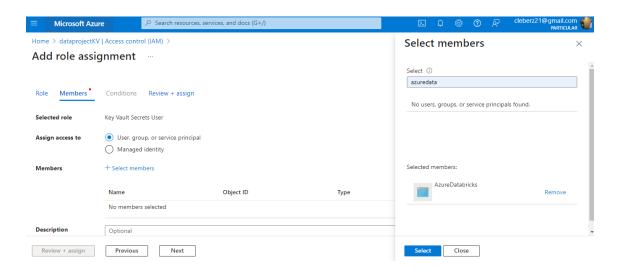
4.4 Key Vault



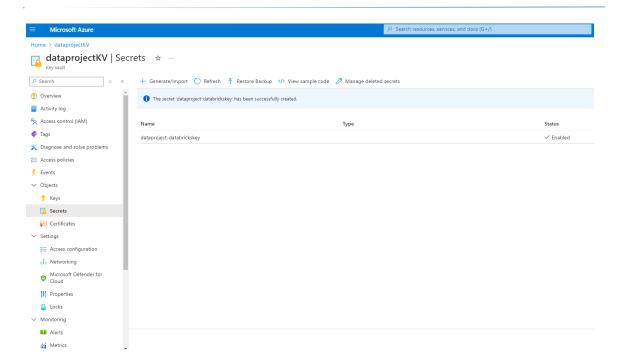
Criação da Key Vault



Adicionando a role Key Vault Secrets Officer



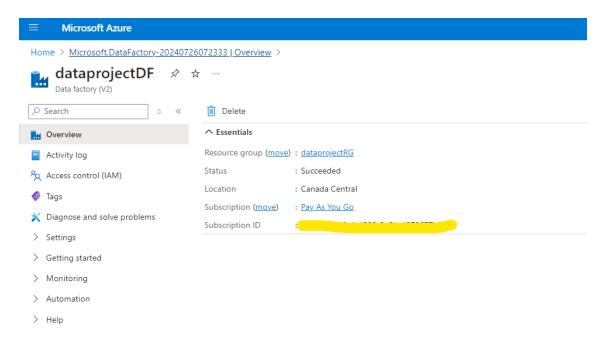
Adicionando membro AzureDatabricks a role Key Vault Secrets Officer



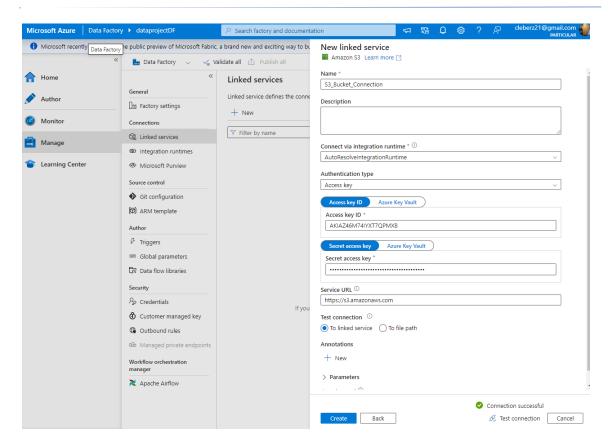
Criando uma secret na Kay Vault dataprojectKV

5 Transferência de Dados para o Azure Data Lake Storage (ADLS)

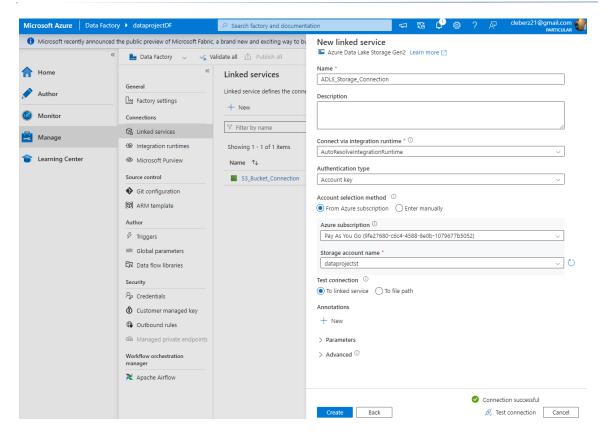
Utilizando o Azure Data Factory, configurei um pipeline de dados para ler o arquivo armazenado no bucket Amazon S3 e transferi-lo para o Azure Data Lake Storage (ADLS). Este processo envolve:



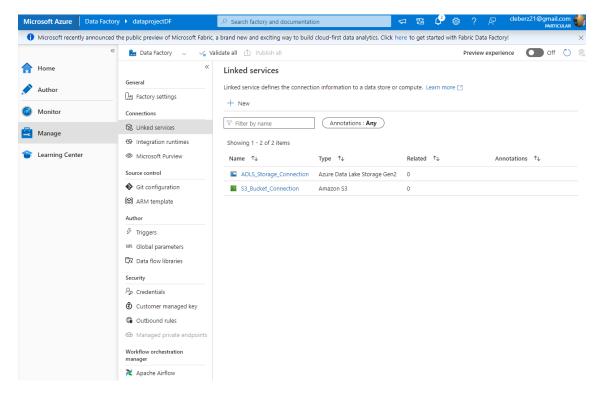
Criação de um Data Factory



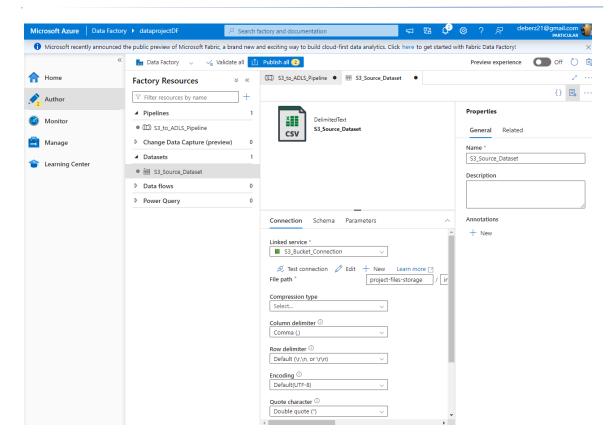
Configuração de um Linked Service no Azure Data Factory para conectar ao bucket S3.



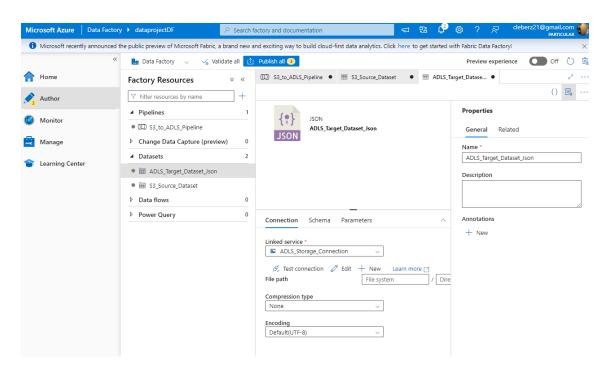
Configuração de um Linked Service no Azure Data Factory para conectar ao ADLS.



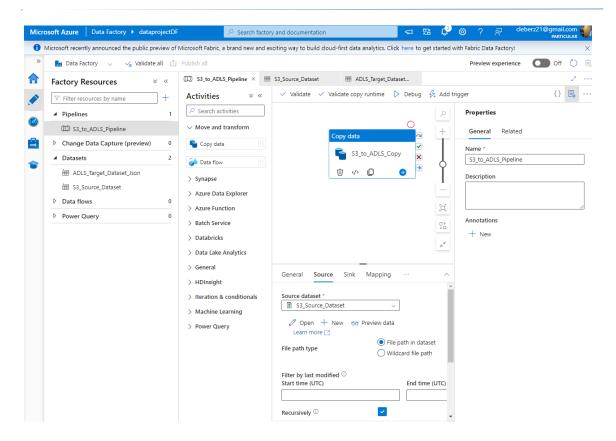
Linked Service criado



Criação de um Dataset que representa a origem dos dados.



Criação de um Dataset que representa o destino dos dados.

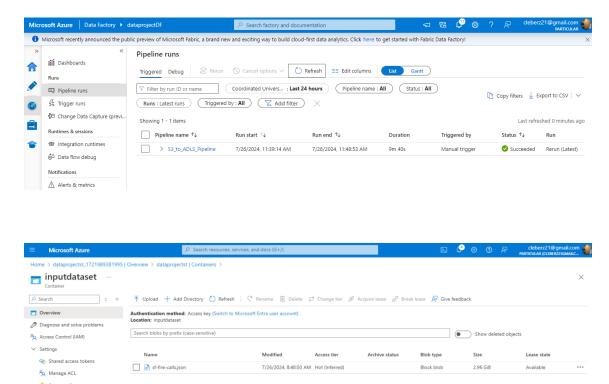


Desenvolvimento de um Pipeline que copia os dados do S3 para o ADLS.

Execução do Pipeline de Dados

Access policy

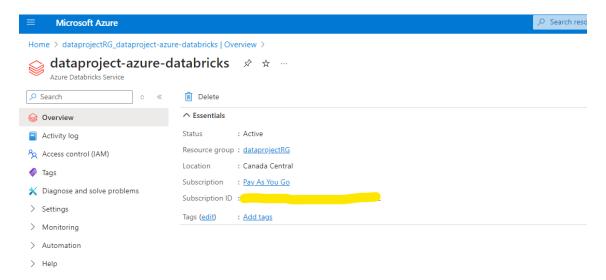
O pipeline de dados foi configurado para executar a transferência de dados de forma eficiente e segura, garantindo que o arquivo sf-fire-calls.csv seja disponibilizado no Data Lake do ADLS, no formato Json, para processamento subsequente no Databricks.

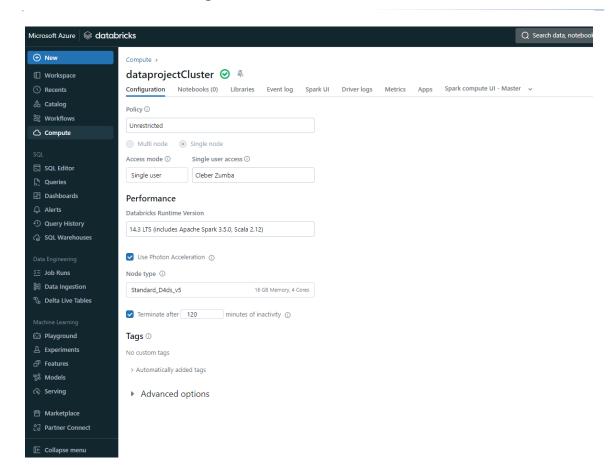


Transferência dos dados concluída

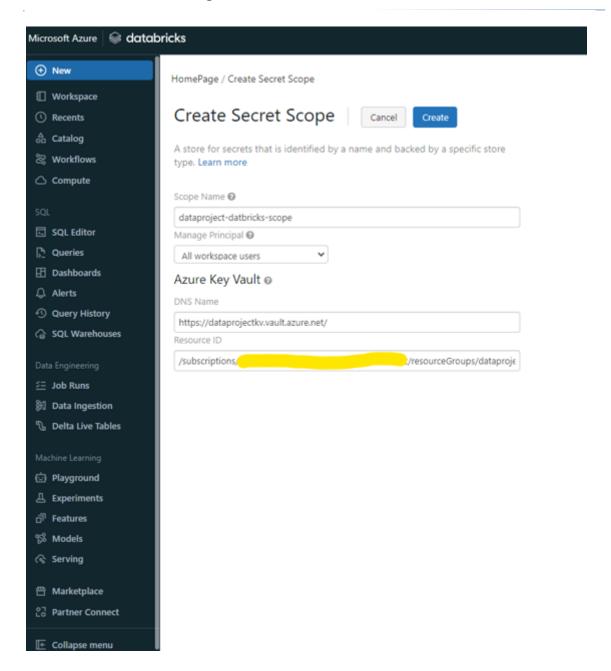
7 Criação do Azure Databricks Workspace e Cluster

O Azure Databricks foi provisionado para realizar a transformação e análise dos dados. Isso inclui a criação de um workspace, um cluster e um secret scope.

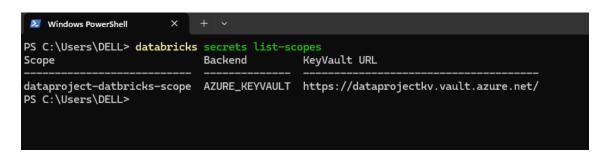




Criação de um Cluster no Databricks

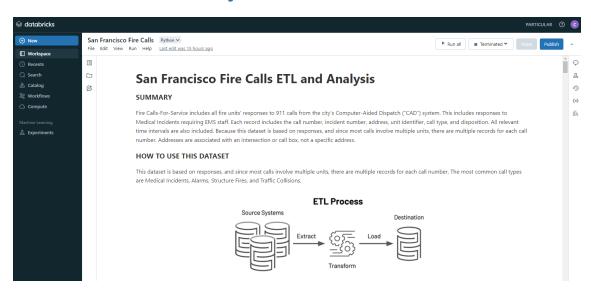


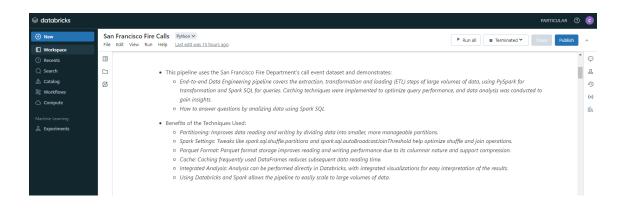
Criação de um Secret Scope no Databricks

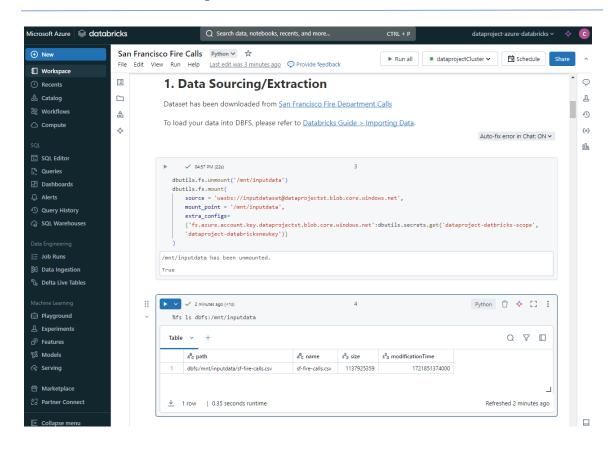


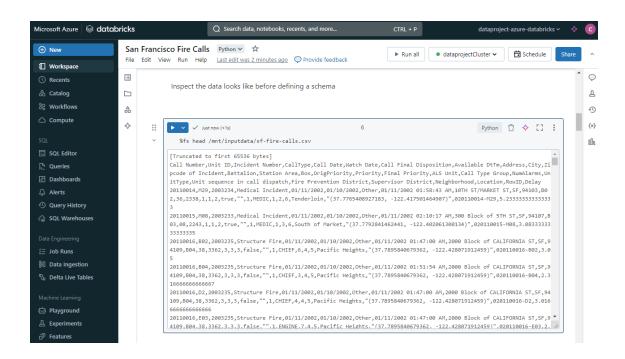
List Scope

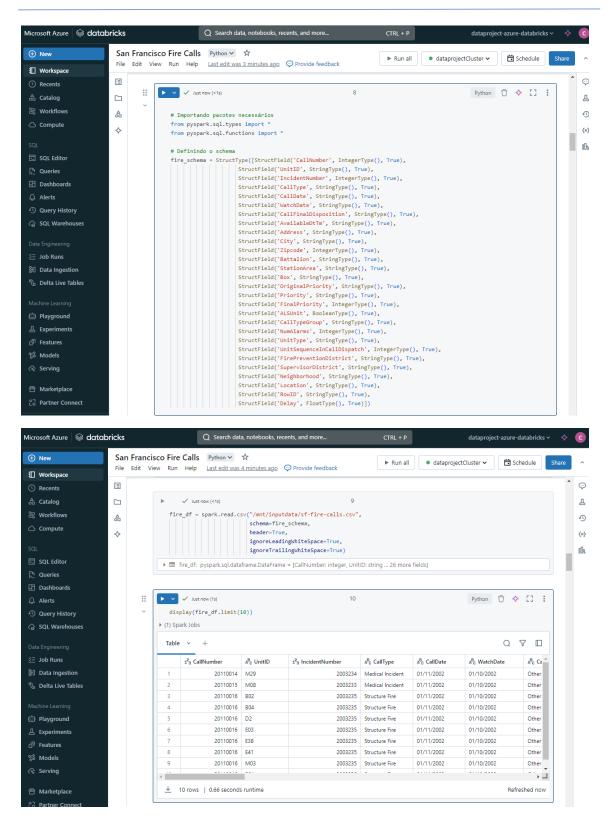
8 Camada de Extração de Dados



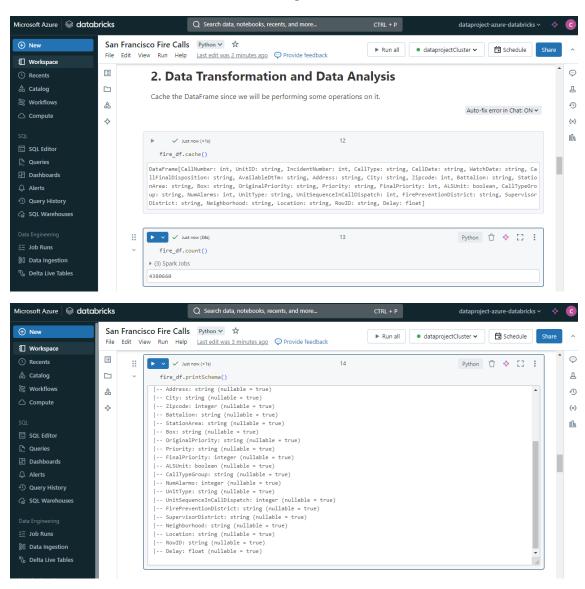


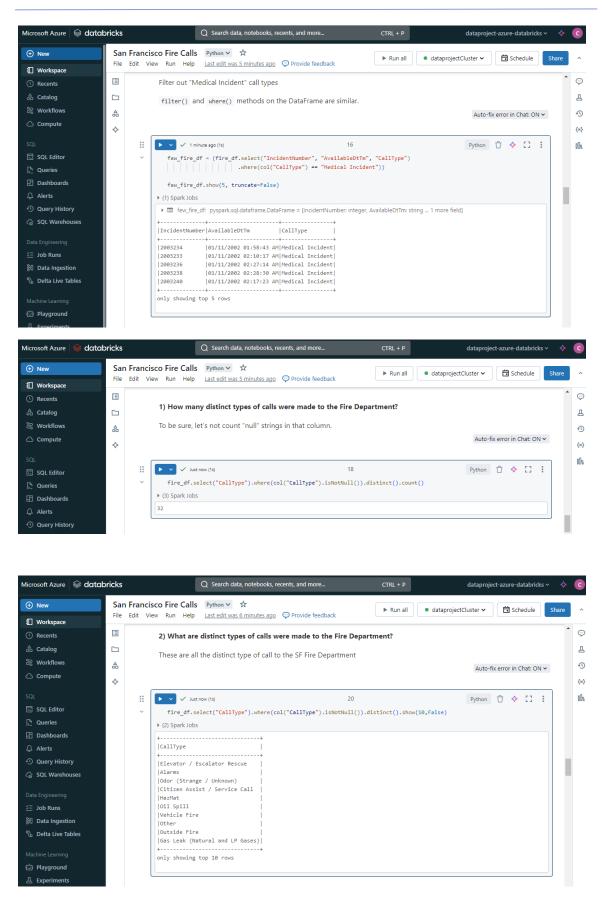


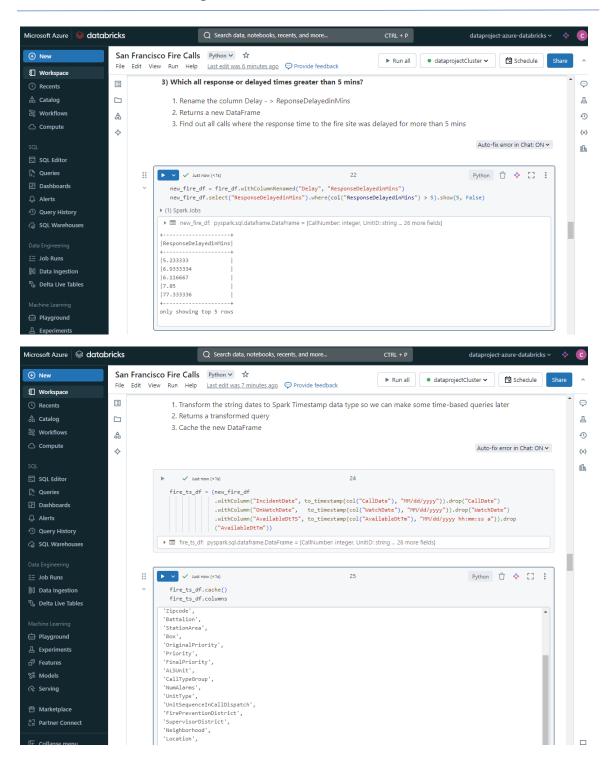


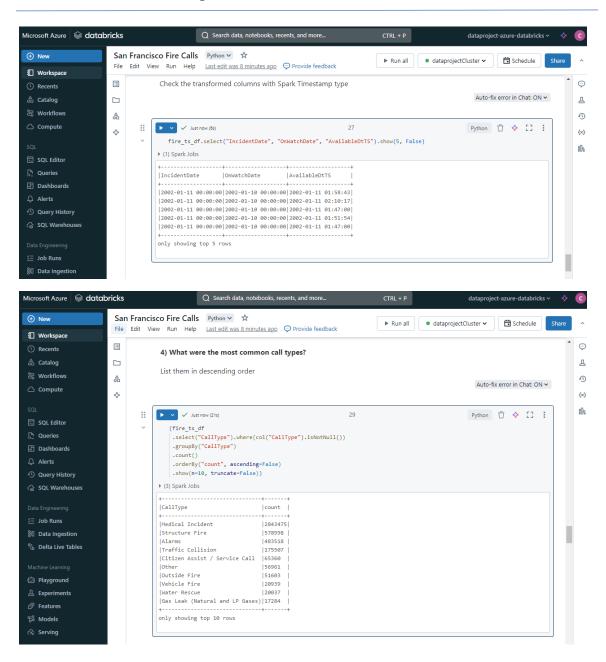


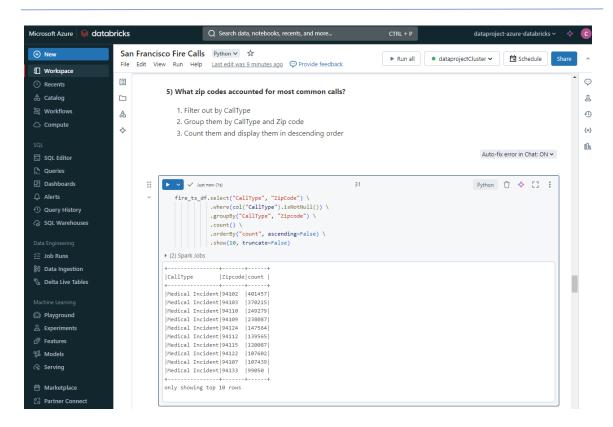
9 Camada de Transformação e Análise de Dados

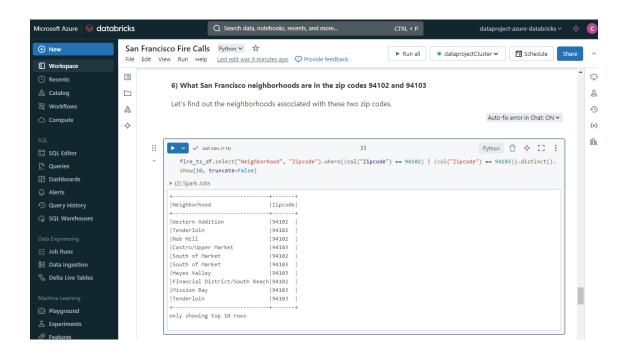


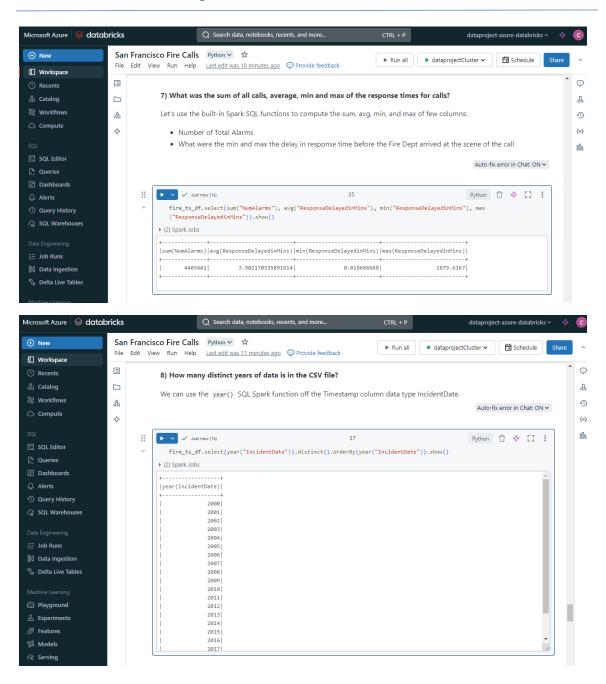


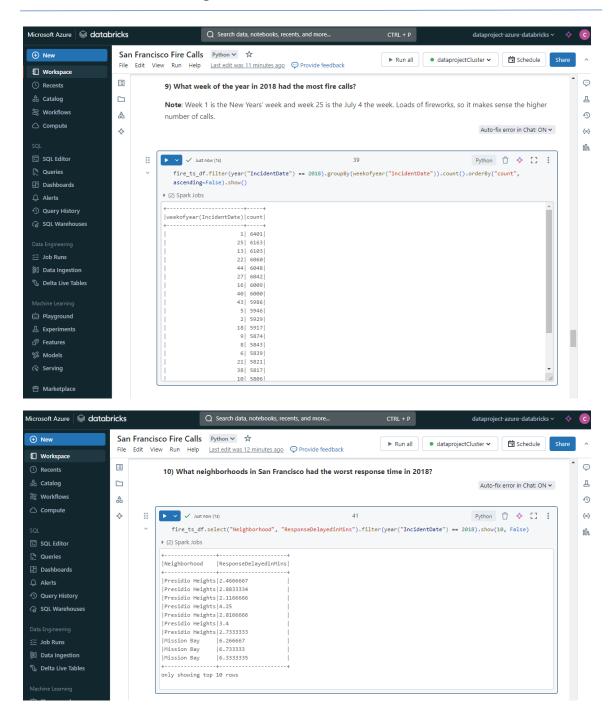




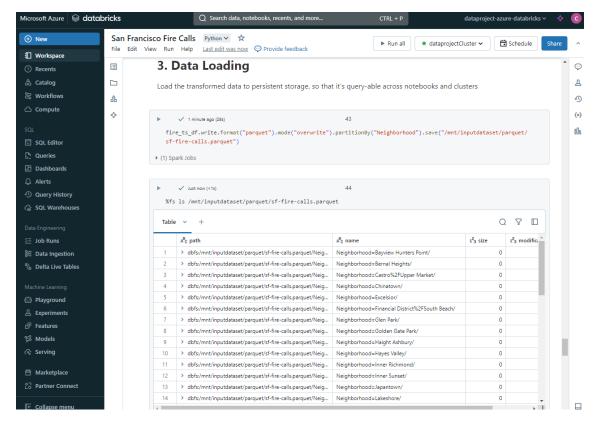




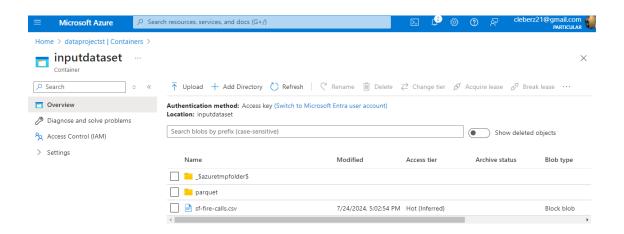




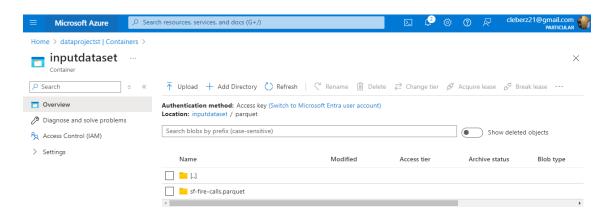
10 Camada de Armazenamento de Dados



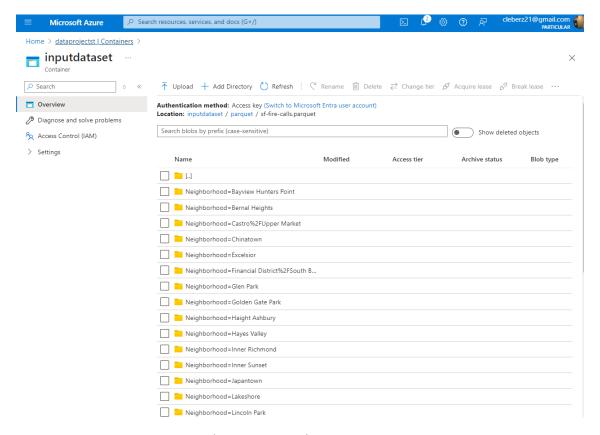
Salvando os dados em formato parquet no sistema de arquivos do Databricks.



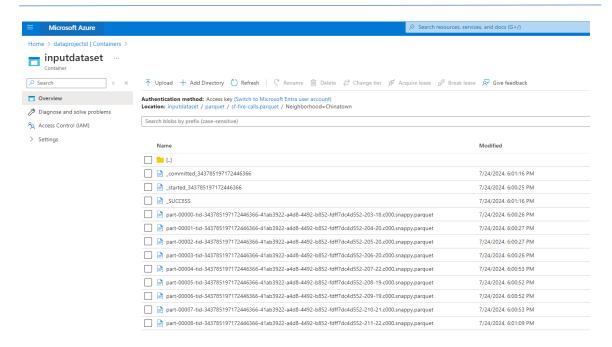
Dados salvos em formato parquet no container do Azure Data Lake Storage (ADLS).



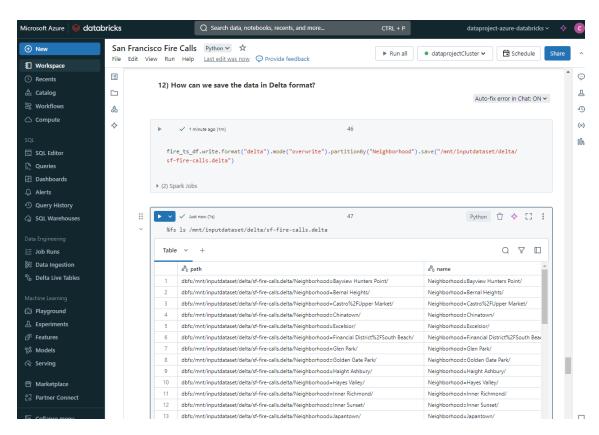
Verificando os dados salvos no container



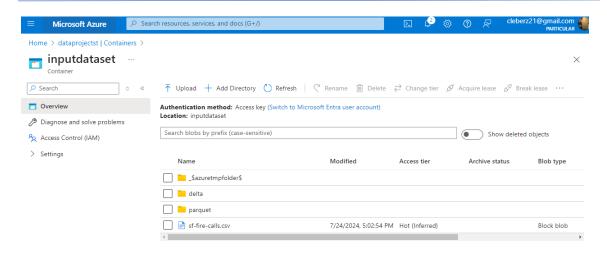
Dados particionados no container



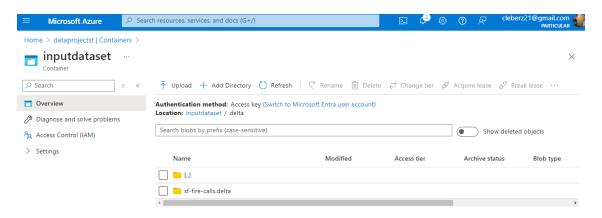
Dados particionados no container



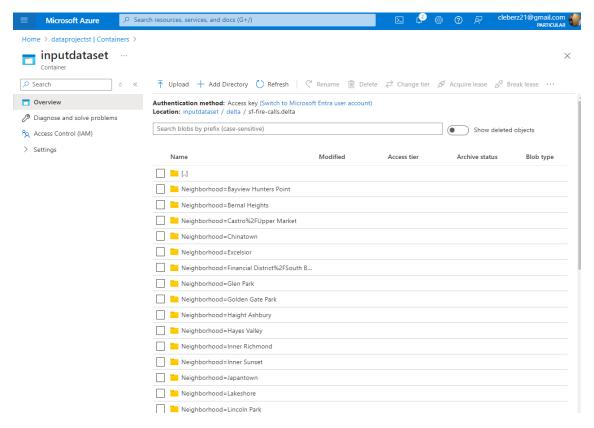
Salvando os dados em formato delta no sistema de arquivos do Databricks.



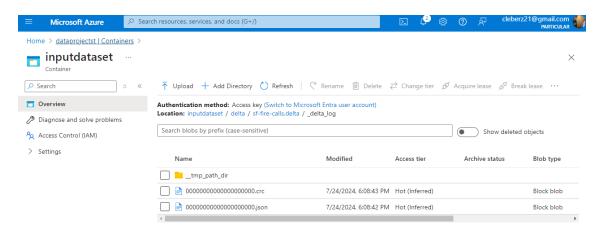
Dados salvos em formato delta no container do Azure Data Lake Storage (ADLS).



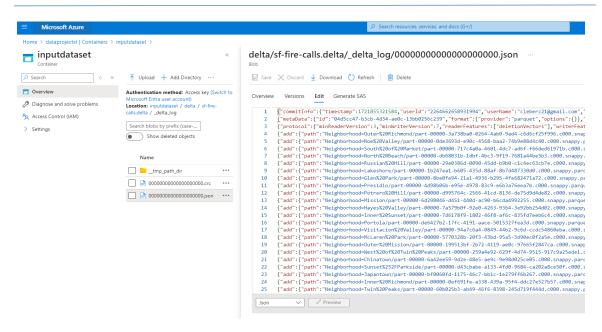
Verificando os dados salvos no container



Dados particionados no container

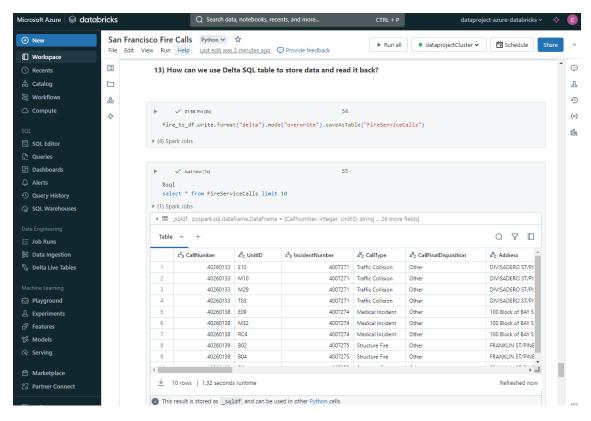


Embora os dados sejam salvos em formato Delta, os arquivos de dados subjacentes estão em formato JSON no container.

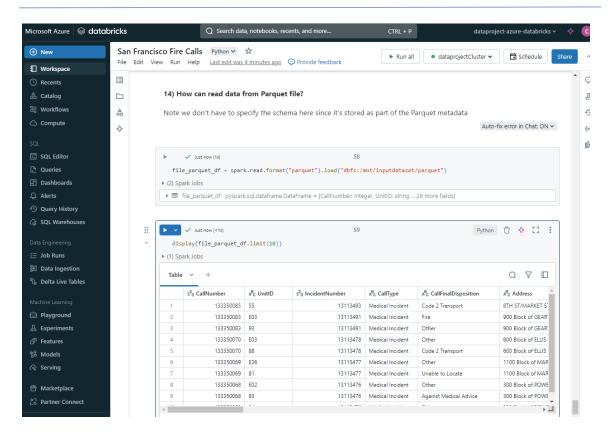


Visualizando os dados no container.

11 Camada de Consulta de Dados



Consultando o resultado da transformação e da análise de dados no formato delta.



Consultando o resultado da transformação e da análise de dados no formato parquet.

12 Conclusão

Neste projeto, explorei os recursos poderosos das tecnologias AWS, Azure e Databricks para criar um pipeline de dados robusto e escalável, focado na análise e transformação de dados de chamadas de emergência do Corpo de Bombeiros de São Francisco.

Realizei processos de extração, transformação e carregamento de dados (ETL), destacando a integração perfeita entre AWS S3, Azure Data Lake Storage (ADLS) e Databricks para processamento de dados escalável. Utilizamos o Azure Data Factory para orquestrar a movimentação de dados e garantir a transferência segura entre os ambientes de nuvem.

No Databricks, utilizei PySpark e SparkSQL para executar consultas e transformações, demonstrando sua capacidade de lidar com análises de dados em larga escala com facilidade. Implementei técnicas de otimização de desempenho, como cache, que são essenciais para atingir o processamento de dados de alto desempenho.

Segui as práticas recomendadas utilizando os recursos avançados do Azure Key Vault para gestão segura de segredos e do Databricks para processamento distribuído.

Cleber Zumba de Souza

13 Referência

PARSIAN, Mahmoud. **Data Algorithms with Spark**. Sebastopol, California, United States: O'Reilly Media, 2022.